

Duale Hochschule Baden-Württemberg

Studienbereich Technik

Informatik

KI-unterstützte Erstellung von ETL-Prozessen

Eine experimentelle Evaluierung

Autor: Luis Geiger

Matrikelnummer: 9144849

Betreuer: Jens Vierling

Unternehmen: Mercedes-Benz Tech Innovation GmbH

Adresse: Gropiusplatz 10, 70563 Stuttgart

Bearbeitungszeitraum: 14.06.2026 - 07.09.2026

Abgabedatum: 2. Mai 2026

Erklärung

Ich erkläre hiermit, dass ich die vorliegende Arbeit selbstständig und ohne fremde Hilfe angefertigt habe. Alle Stellen, die ich wörtlich oder dem Sinne nach aus anderen Arbeiten übernommen habe, sind durch genaue Quellenangaben gekennzeichnet.

Ort, Datum:

Luis Geiger

Unterschrift:

Inhaltsverzeichnis

1	Einleitung	1
1.1	Motivation und Problemstellung	1
1.2	Zielsetzung und Forschungsfragen	1
1.3	Methodisches Vorgehen	1
1.4	Aufbau der Arbeit	1
2	Grundlagen	2
2.1	ETL-Prozesse	2
2.1.1	Definition und Phasen	2
2.1.2	Typische Herausforderungen	2
2.1.3	Klassische Werkzeuge und Verfahren	2
2.2	Datenqualität und Datenbereinigung	2
2.2.1	Dimensionen der Datenqualität	2
2.2.2	Häufige Datenprobleme	2
2.3	Large Language Models	2
2.3.1	Funktionsweise und Architektur	2
2.3.2	Überblick aktueller Modelle	2
2.3.3	Stärken und Limitationen bei strukturierten Daten	2
2.4	Prompt Engineering	2
2.4.1	Grundlegende Prompting-Strategien	2
2.4.2	Einflussfaktoren auf die Ergebnisqualität	2
3	Stand der Forschung	3
3.1	KI-Einsatz in der Datenverarbeitung	3
3.2	LLMs für strukturierte Daten und Tabellen	3
3.3	Verwandte Arbeiten zur Automatisierung von ETL	3
3.4	Forschungslücke und Abgrenzung	3
4	Konzeption der experimentellen Evaluierung	4
4.1	Forschungsdesign und Hypothesen	4
4.2	Auswahl der Large Language Models	4
4.3	Definition der ETL-Aufgaben	4
4.3.1	Datenbereinigung	4
4.3.2	Datentransformation	4

4.3.3	Duplikaterkennung	4
4.4	Prompting-Strategien	4
4.5	Evaluationskriterien	4
4.5.1	Genauigkeit	4
4.5.2	Vollständigkeit	4
4.5.3	Konsistenz	4
4.5.4	Effizienz	4
4.6	Vergleich mit klassischen Methoden als Baseline	4
5	Erstellung des synthetischen Datensatzes	5
5.1	Anforderungen an den Datensatz	5
5.2	Datenmodell und -struktur	5
5.3	Eingebaute Datenqualitätsprobleme	5
5.4	Generierungsverfahren und verwendete Werkzeuge	5
5.5	Validierung des Datensatzes	5
6	Implementierung	6
6.1	Systemarchitektur und Versuchsumgebung	6
6.2	Eingesetzte Technologien und Bibliotheken	6
6.3	Umsetzung der klassischen ETL-Pipeline	6
6.4	Integration der LLMs in die Pipeline	6
6.5	Umsetzung der Prompting-Strategien	6
6.6	Mess- und Auswertungsverfahren	6
7	Durchführung der Experimente	7
7.1	Versuchsablauf	7
7.2	Erhobene Messdaten	7
7.3	Reproduzierbarkeit und Versuchsbedingungen	7
8	Ergebnisse und Auswertung	8
8.1	Ergebnisse je ETL-Aufgabe	8
8.2	Vergleich der Modelle	8
8.3	Vergleich der Prompting-Strategien	8
8.4	Vergleich KI-basiert vs. klassisch	8
8.5	Diskussion der Ergebnisse	8
8.5.1	Stärken des LLM-Einsatzes	8
8.5.2	Schwächen und Risiken	8
8.5.3	Einordnung in den Stand der Forschung	8
9	Handlungsempfehlungen für die Praxis	9
9.1	Eignung von LLMs für unterschiedliche ETL-Szenarien	9
9.2	Empfehlungen zur Modell- und Prompt-Auswahl	9

9.3	Hybride Architekturen	9
10	Fazit und Ausblick	10
10.1	Zusammenfassung der Ergebnisse	10
10.2	Beantwortung der Forschungsfragen	10
10.3	Limitationen der Arbeit	10
10.4	Ausblick auf weitere Forschung	10

Abbildungsverzeichnis

Tabellenverzeichnis

1 Einleitung

1.1 Motivation und Problemstellung

1.2 Zielsetzung und Forschungsfragen

1.3 Methodisches Vorgehen

1.4 Aufbau der Arbeit

2 Grundlagen

2.1 ETL-Prozesse

2.1.1 Definition und Phasen

2.1.2 Typische Herausforderungen

2.1.3 Klassische Werkzeuge und Verfahren

2.2 Datenqualität und Datenbereinigung

2.2.1 Dimensionen der Datenqualität

2.2.2 Häufige Datenprobleme

2.3 Large Language Models

2.3.1 Funktionsweise und Architektur

2.3.2 Überblick aktueller Modelle

2.3.3 Stärken und Limitationen bei strukturierten Daten

2.4 Prompt Engineering

2.4.1 Grundlegende Prompting-Strategien

2.4.2 Einflussfaktoren auf die Ergebnisqualität

3 Stand der Forschung

3.1 KI-Einsatz in der Datenverarbeitung

3.2 LLMs für strukturierte Daten und Tabellen

3.3 Verwandte Arbeiten zur Automatisierung von ETL

3.4 Forschungslücke und Abgrenzung

4 Konzeption der experimentellen Evaluierung

4.1 Forschungsdesign und Hypothesen

4.2 Auswahl der Large Language Models

4.3 Definition der ETL-Aufgaben

4.3.1 Datenbereinigung

4.3.2 Datentransformation

4.3.3 Duplikaterkennung

4.4 Prompting-Strategien

4.5 Evaluationskriterien

4.5.1 Genauigkeit

4.5.2 Vollständigkeit

4.5.3 Konsistenz

4.5.4 Effizienz

4.6 Vergleich mit klassischen Methoden als Baseline

5 Erstellung des synthetischen Datensatzes

5.1 Anforderungen an den Datensatz

5.2 Datenmodell und -struktur

5.3 Eingebaute Datenqualitätsprobleme

5.4 Generierungsverfahren und verwendete Werkzeuge

5.5 Validierung des Datensatzes

6 Implementierung

6.1 Systemarchitektur und Versuchsumgebung

6.2 Eingesetzte Technologien und Bibliotheken

6.3 Umsetzung der klassischen ETL-Pipeline

6.4 Integration der LLMs in die Pipeline

6.5 Umsetzung der Prompting-Strategien

6.6 Mess- und Auswertungsverfahren

7 Durchführung der Experimente

7.1 Versuchsablauf

7.2 Erhobene Messdaten

7.3 Reproduzierbarkeit und Versuchsbedingungen

8 Ergebnisse und Auswertung

8.1 Ergebnisse je ETL-Aufgabe

8.2 Vergleich der Modelle

8.3 Vergleich der Prompting-Strategien

8.4 Vergleich KI-basiert vs. klassisch

8.5 Diskussion der Ergebnisse

8.5.1 Stärken des LLM-Einsatzes

8.5.2 Schwächen und Risiken

8.5.3 Einordnung in den Stand der Forschung

9 Handlungsempfehlungen für die Praxis

9.1 Eignung von LLMs für unterschiedliche ETL-Szenarien

9.2 Empfehlungen zur Modell- und Prompt-Auswahl

9.3 Hybride Architekturen

10 Fazit und Ausblick

10.1 Zusammenfassung der Ergebnisse

10.2 Beantwortung der Forschungsfragen

10.3 Limitationen der Arbeit

10.4 Ausblick auf weitere Forschung