

KI-unterstützte Erstellung von ETL-Prozessen - Eine experimentelle Evaluierung

Bachelorarbeit

for the examination for

Bachelor of Science

of Computer Science

at Baden-Wuerttemberg Cooperative State University (DHBW) Stuttgart

by

Luis Geiger

02.05.2026

Matriculation Number:	9144849
Course:	TINF23CE
Reviewer at DHBW Stuttgart:	Prof. Dr. Name

Erklärung

Ich erkläre mich hiermit ehrenwörtlich, dass ich die vorliegende Arbeit Bachelorarbeit mit dem Thema „*KI-unterstützte Erstellung von ETL-Prozessen - Eine experimentelle Evaluierung*“ selbständig und ohne Benutzung anderer als der angegebenen Hilfsmittel angefertigt habe. Aus den benutzten Quellen, direkt oder indirekt, übernommene Gedanken habe ich als solche kenntlich gemacht. Diese Arbeit wurde bisher in gleicher oder ähnlicher Form oder auszugsweise noch keiner anderen Prüfungsbehörde vorgelegt und auch nicht veröffentlicht.

Stuttgart, 02.05.2026

Ort, Datum

L.Geiger

Luis Geiger

Zusammenfassung / Abstract

deutsch

englisch

Contents

List of Figures	VI
List of Tables	VI
Anhang	VIII
0.1 Anhang 1	VIII
0.2 Anhang 2	VIII
1 Einleitung	2
1.1 Motivation und Problemstellung	2
1.2 Zielsetzung und Forschungsfragen	2
1.3 Methodisches Vorgehen	2
1.4 Aufbau der Arbeit	2
2 Grundlagen	2
2.1 ETL-Prozesse	2
2.1.1 Definition und Phasen	2
2.1.2 Typische Herausforderungen	2
2.1.3 Klassische Werkzeuge und Verfahren	2
2.2 Datenqualität und Datenbereinigung	2
2.2.1 Dimensionen der Datenqualität	2
2.2.2 Häufige Datenprobleme	2
2.3 Large Language Models	2
2.3.1 Funktionsweise und Architektur	2
2.3.2 Überblick aktueller Modelle	2
2.3.3 Stärken und Limitationen bei strukturierten Daten	2
2.4 Prompt Engineering	2
2.4.1 Grundlegende Prompting-Strategien	2
2.4.2 Einflussfaktoren auf die Ergebnisqualität	2
3 Stand der Forschung	2
3.1 KI-Einsatz in der Datenverarbeitung	2
3.2 LLMs für strukturierte Daten und Tabellen	2
3.3 Verwandte Arbeiten zur Automatisierung von ETL	2
3.4 Forschungslücke und Abgrenzung	2
4 Konzeption der experimentellen Evaluierung	2
4.1 Forschungsdesign und Hypothesen	2

4.2	Auswahl der Large Language Models	2
4.3	Definition der ETL-Aufgaben	2
4.3.1	Datenbereinigung	2
4.3.2	Datentransformation	2
4.3.3	Duplikaterkennung	2
4.4	Prompting-Strategien	2
4.5	Evaluationskriterien	2
4.5.1	Genauigkeit	2
4.5.2	Vollständigkeit	2
4.5.3	Konsistenz	2
4.5.4	Effizienz	2
4.6	Vergleich mit klassischen Methoden als Baseline	2
5	Erstellung des synthetischen Datensatzes	2
5.1	Anforderungen an den Datensatz	2
5.2	Datenmodell und -struktur	2
5.3	Eingebaute Datenqualitätsprobleme	2
5.4	Generierungsverfahren und verwendete Werkzeuge	2
5.5	Validierung des Datensatzes	2
6	Implementierung	2
6.1	Systemarchitektur und Versuchsumgebung	2
6.2	Eingesetzte Technologien und Bibliotheken	2
6.3	Umsetzung der klassischen ETL-Pipeline	2
6.4	Integration der LLMs in die Pipeline	2
6.5	Umsetzung der Prompting-Strategien	2
6.6	Mess- und Auswertungsverfahren	2
7	Durchführung der Experimente	2
7.1	Versuchsablauf	2
7.2	Erhobene Messdaten	2
7.3	Reproduzierbarkeit und Versuchsbedingungen	2
8	Ergebnisse und Auswertung	2
8.1	Ergebnisse je ETL-Aufgabe	2
8.2	Vergleich der Modelle	2
8.3	Vergleich der Prompting-Strategien	2
8.4	Vergleich KI-basiert vs. klassisch	2
8.5	Diskussion der Ergebnisse	2
8.5.1	Stärken des LLM-Einsatzes	2

8.5.2	Schwächen und Risiken	2
8.5.3	Einordnung in den Stand der Forschung	2
9	Handlungsempfehlungen für die Praxis	2
9.1	Eignung von LLMs für unterschiedliche ETL-Szenarien	2
9.2	Empfehlungen zur Modell- und Prompt-Auswahl	2
9.3	Hybride Architekturen	2
10	Fazit und Ausblick	2
10.1	Zusammenfassung der Ergebnisse	2
10.2	Beantwortung der Forschungsfragen	2
10.3	Limitationen der Arbeit	2
10.4	Ausblick auf weitere Forschung	2

List of Figures

List of Tables

API Application Programming Interface

DB Datenbank

DHBW Duale Hochschule Baden-Württemberg

HTTP Hypertext Transfer Protocol

JSON JavaScript Object Notation

SQL Structured Query Language

XML Extensible Markup Language

Anhang

- 0.1 Anhang 1 VIII
- 0.2 Anhang 2 VIII

0.1 Anhang 1

0.2 Anhang 2

1. Einleitung

1.1 Motivation und Problemstellung

1.2 Zielsetzung und Forschungsfragen

1.3 Methodisches Vorgehen

1.4 Aufbau der Arbeit

2. Grundlagen

2.1 ETL-Prozesse

2.1.1 Definition und Phasen

2.1.2 Typische Herausforderungen

2.1.3 Klassische Werkzeuge und Verfahren

2.2 Datenqualität und Datenbereinigung

2.2.1 Dimensionen der Datenqualität

2.2.2 Häufige Datenprobleme

2.3 Large Language Models

2.3.1 Funktionsweise und Architektur

2.3.2 Überblick aktueller Modelle

2.3.3 Stärken und Limitationen bei strukturierten Daten

2.4 Prompt Engineering