

KI-unterstützte Erstellung von ETL-Prozessen - Eine experimentelle Evaluierung

Bachelorarbeit

for the examination for

Bachelor of Science

of Informatik

at Baden-Wuerttemberg Cooperative State University (DHBW) Stuttgart

by

Luis Geiger

02.05.2026

Matriculation Number:	9144849
Course:	TINF23CE
Reviewer at DHBW Stuttgart:	Prof. Dr. Name

Erklärung

Ich erkläre mich hiermit ehrenwörtlich, dass ich die vorliegende Arbeit Bachelorarbeit mit dem Thema „*KI-unterstützte Erstellung von ETL-Prozessen - Eine experimentelle Evaluierung*“ selbständig und ohne Benutzung anderer als der angegebenen Hilfsmittel angefertigt habe. Aus den benutzten Quellen, direkt oder indirekt, übernommene Gedanken habe ich als solche kenntlich gemacht. Diese Arbeit wurde bisher in gleicher oder ähnlicher Form oder auszugsweise noch keiner anderen Prüfungsbehörde vorgelegt und auch nicht veröffentlicht.

Stuttgart, 02.05.2026

Ort, Datum

L.Geiger

Luis Geiger

Contents

Abkürzungsverzeichnis	V
1 Einleitung	1
1.1 Motivation und Problemstellung	1
1.2 Zielsetzung und Forschungsfragen	2
1.3 Methodisches Vorgehen	2
1.4 Aufbau der Arbeit	3
2 Grundlagen	6
2.1 ETL-Prozesse	6
2.1.1 Definition und Phasen	6
2.1.2 Typische Herausforderungen	6
2.1.3 Klassische Werkzeuge und Verfahren	6
2.2 Datenqualität und Datenbereinigung	6
2.2.1 Dimensionen der Datenqualität	6
2.2.2 Häufige Datenprobleme	6
2.3 Large Language Models	6
2.3.1 Funktionsweise und Architektur	6
2.3.2 Überblick aktueller Modelle	6
2.3.3 Stärken und Limitationen bei strukturierten Daten	6
2.4 Prompt Engineering	6
2.4.1 Grundlegende Prompting-Strategien	6
2.4.2 Einflussfaktoren auf die Ergebnisqualität	6
3 Stand der Forschung	6
3.1 KI-Einsatz in der Datenverarbeitung	6
3.2 LLMs für strukturierte Daten und Tabellen	6
3.3 Verwandte Arbeiten zur Automatisierung von ETL	6
3.4 Forschungslücke und Abgrenzung	6
4 Konzeption der experimentellen Evaluierung	6
4.1 Forschungsdesign und Hypothesen	6
4.2 Auswahl der Large Language Models	6
4.3 Definition der ETL-Aufgaben	6
4.3.1 Datenbereinigung	6
4.3.2 Datentransformation	6
4.3.3 Duplikaterkennung	6

4.4	Prompting-Strategien	6
4.5	Evaluationskriterien	6
4.5.1	Genauigkeit	6
4.5.2	Vollständigkeit	6
4.5.3	Konsistenz	6
4.5.4	Effizienz	6
4.6	Vergleich mit klassischen Methoden als Baseline	6
5	Erstellung des synthetischen Datensatzes	6
5.1	Anforderungen an den Datensatz	6
5.2	Datenmodell und -struktur	6
5.3	Eingebaute Datenqualitätsprobleme	6
5.4	Generierungsverfahren und verwendete Werkzeuge	6
5.5	Validierung des Datensatzes	6
6	Implementierung	6
6.1	Systemarchitektur und Versuchsumgebung	6
6.2	Eingesetzte Technologien und Bibliotheken	6
6.3	Umsetzung der klassischen ETL-Pipeline	6
6.4	Integration der LLMs in die Pipeline	6
6.5	Umsetzung der Prompting-Strategien	6
6.6	Mess- und Auswertungsverfahren	6
7	Durchführung der Experimente	6
7.1	Versuchsablauf	6
7.2	Erhobene Messdaten	6
7.3	Reproduzierbarkeit und Versuchsbedingungen	6
8	Ergebnisse und Auswertung	6
8.1	Ergebnisse je ETL-Aufgabe	6
8.2	Vergleich der Modelle	6
8.3	Vergleich der Prompting-Strategien	6
8.4	Vergleich KI-basiert vs. klassisch	6
8.5	Diskussion der Ergebnisse	6
8.5.1	Stärken des LLM-Einsatzes	6
8.5.2	Schwächen und Risiken	6
8.5.3	Einordnung in den Stand der Forschung	6
9	Handlungsempfehlungen für die Praxis	6
9.1	Eignung von LLMs für unterschiedliche ETL-Szenarien	6

9.2	Empfehlungen zur Modell- und Prompt-Auswahl	6
9.3	Hybride Architekturen	6
10	Fazit und Ausblick	6
10.1	Zusammenfassung der Ergebnisse	6
10.2	Beantwortung der Forschungsfragen	6
10.3	Limitationen der Arbeit	6
10.4	Ausblick auf weitere Forschung	6
	Bibliography	7

Abkürzungsverzeichnis

ETL Extract, Transform, Load

LLM Large Language Model

AI Künstliche Intelligenz

1. Einleitung

1.1 Motivation und Problemstellung

Die Verfügbarkeit, Qualität und zeitnahe Bereitstellung von Daten sind zu einem zentralen Erfolgsfaktor für datengetriebene Organisationen geworden. Im Zentrum der dafür notwendigen Dateninfrastruktur stehen seit Jahrzehnten ETL-Prozesse (Extract, Transform, Load), die Daten aus heterogenen Quellsystemen extrahieren, in eine einheitliche Struktur überführen und in Zielsysteme wie Data Warehouses oder Analyseplattformen laden (B. Khan et al., 2024; Walha et al., 2024). Trotz ihrer langen Etablierung gelten klassische ETL-Pipelines zunehmend als Engpass: Sie sind in der Regel regelbasiert, statisch modelliert und erfordern erheblichen manuellen Aufwand bei Entwurf, Anpassung und Wartung (Mishra, 2020; Nagabhyru, 2022). Mit dem Wachstum von Datenvolumen, der Heterogenität der Quellen und steigenden Anforderungen an Aktualität geraten herkömmliche ETL-Architekturen an ihre Grenzen (Ravi, 2025; Walha et al., 2024). Parallel dazu haben sich in den letzten Jahren Large Language Models (LLMs) als leistungsfähige Werkzeuge etabliert, die nicht nur natürliche Sprache, sondern zunehmend auch strukturierte und semi-strukturierte Daten verarbeiten können (Zhao et al., 2026). Erste Arbeiten zeigen, dass LLMs im Kontext der Datenverarbeitung Aufgaben wie Datenbereinigung, Schema-Mapping, Transformationslogik oder Anomalieerkennung übernehmen oder zumindest unterstützen können (Chakraborty, 2025; Hassani & Silva, 2023; J. Khan, 2025). Damit eröffnet sich die Perspektive, klassische ETL-Prozesse durch KI-gestützte Komponenten zu ergänzen oder partiell zu ersetzen, um manuellen Aufwand zu reduzieren und die Anpassungsfähigkeit der Pipelines zu erhöhen. Gleichzeitig ist die praktische Eignung von LLMs für ETL-Aufgaben bislang nur unzureichend systematisch untersucht. Während konzeptionelle Beiträge die potenziellen Vorteile beschreiben, fehlt es an empirischen Vergleichen, die unterschiedliche Modelle und Prompting-Strategien unter kontrollierten Bedingungen gegen klassische Verfahren stellen. Offen ist insbesondere, wie zuverlässig LLMs typische ETL-Teilaufgaben wie Datenbereinigung, Datentransformation und Duplikaterkennung bearbeiten, wie stabil und reproduzierbar ihre Ergebnisse aufgrund der probabilistischen Modellarchitektur ausfallen, wie sich verschiedene Prompting-Ansätze auf die Ergebnisqualität auswirken und unter welchen Bedingungen ein Einsatz gegenüber etablierten regelbasierten Methoden überhaupt sinnvoll ist. Genau an dieser Lücke setzt die vorliegende Arbeit an.

1.2 Zielsetzung und Forschungsfragen

Ziel dieser Arbeit ist eine experimentelle Evaluierung der Eignung von Large Language Models für die Unterstützung und Automatisierung ausgewählter ETL-Aufgaben. Im Zentrum steht der systematische Vergleich mehrerer aktueller LLMs sowie unterschiedlicher Prompting-Strategien anhand eines kontrolliert erstellten synthetischen Datensatzes, der typische Datenqualitätsprobleme abbildet. Die Ergebnisse werden mit einer klassisch implementierten ETL-Pipeline als Baseline verglichen, um Stärken, Schwächen und praktische Einsatzgrenzen KI-gestützter Ansätze fundiert einordnen zu können. Auf dieser Grundlage sollen Handlungsempfehlungen für den Einsatz von LLMs in realen ETL-Szenarien abgeleitet werden. Aus dieser Zielsetzung ergeben sich folgende Forschungsfragen:

FF1: Inwieweit eignen sich aktuelle Large Language Models für die Bearbeitung typischer ETL-Aufgaben – konkret Datenbereinigung, Datentransformation und Duplikaterkennung – im Vergleich zu einer klassischen, regelbasierten ETL-Pipeline?

FF2: Welchen Einfluss haben unterschiedliche Prompting-Strategien auf die Ergebnisqualität der untersuchten LLMs in den definierten ETL-Aufgaben?

FF3: Wie reproduzierbar und stabil sind die Ergebnisse der LLM-gestützten Verarbeitung bei wiederholter Ausführung identischer ETL-Aufgaben?

FF4: Unter welchen Bedingungen ist ein KI-gestützter, hybrider oder klassischer Ansatz für unterschiedliche ETL-Szenarien zu empfehlen?

1.3 Methodisches Vorgehen

Zur Beantwortung der formulierten Forschungsfragen wird ein mehrstufiges, experimentell ausgerichtetes Vorgehen gewählt, das konzeptionelle, gestalterische und empirische Elemente miteinander verbindet. Den Ausgangspunkt bildet eine strukturierte Aufarbeitung der theoretischen Grundlagen zu ETL-Prozessen, Datenqualität, Large Language Models und Prompt Engineering sowie eine Analyse des aktuellen Forschungsstands zum Einsatz von KI in der Datenintegration. Diese literaturbasierte Vorarbeit dient dazu, relevante Konzepte, etablierte Verfahren und bestehende Forschungslücken zu identifizieren und die anschließende Evaluierung theoretisch zu fundieren. Auf

dieser Grundlage wird in einem zweiten Schritt das experimentelle Design entwickelt. Dazu zählen die Auswahl mehrerer aktueller Large Language Models, die Definition der zu untersuchenden ETL-Teilaufgaben Datenbereinigung, Datentransformation und Duplikaterkennung sowie die Festlegung unterschiedlicher Prompting-Strategien. Ergänzend werden Evaluationskriterien operationalisiert, anhand derer die Ergebnisse aller Verfahren vergleichbar gemessen werden können. Da Large Language Models aufgrund ihrer probabilistischen Natur nicht-deterministische Ausgaben erzeugen können, wird zusätzlich die Reproduzierbarkeit der Ergebnisse als eigenständige Untersuchungsdimension berücksichtigt. Als Vergleichsmaßstab dient eine klassische, regelbasiert implementierte ETL-Pipeline, die als Baseline fungiert. Im dritten Schritt wird ein synthetischer Datensatz erstellt, der typische Datenqualitätsprobleme realer Datenbestände kontrolliert abbildet. Die gezielte Konstruktion erlaubt es, die Eigenschaften der Eingangsdaten exakt zu kennen und damit reproduzierbare sowie aussagekräftige Vergleiche zwischen den untersuchten Ansätzen zu ermöglichen. Anschließend erfolgt die technische Umsetzung der Versuchsumgebung, in der sowohl die klassische ETL-Pipeline als auch die LLM-basierten Verarbeitungsschritte implementiert und über einheitliche Schnittstellen ausgeführt werden. Die eigentliche Durchführung der Experimente erfolgt unter standardisierten Bedingungen, wobei für jede Kombination aus Modell, Prompting-Strategie und ETL-Aufgabe Messdaten zu Qualität, Stabilität und Effizienz erhoben werden. Um die Reproduzierbarkeit der LLM-Ergebnisse beurteilen zu können, wird jede Konfiguration mehrfach ausgeführt. Die Auswertung kombiniert eine quantitative Analyse der definierten Kennzahlen mit einer qualitativen Einordnung beobachteter Stärken und Schwächen. Aus den Ergebnissen werden abschließend Handlungsempfehlungen abgeleitet, die eine fundierte Einschätzung über den sinnvollen Einsatz von LLMs in unterschiedlichen ETL-Szenarien ermöglichen.

1.4 Aufbau der Arbeit

Die vorliegende Arbeit gliedert sich in zehn Kapitel. Nach der vorliegenden Einleitung, in der Motivation, Zielsetzung, Forschungsfragen und methodisches Vorgehen dargelegt werden, behandelt Kapitel 2 die theoretischen Grundlagen. Hier werden zentrale Konzepte zu ETL-Prozessen, Datenqualität, Large Language Models sowie Prompt Engineering eingeführt, die als Bezugsrahmen für die weitere Untersuchung dienen. Kapitel 3 widmet sich dem aktuellen Stand der Forschung. Es werden Arbeiten zum Einsatz von KI in der Datenverarbeitung, zur Verarbeitung strukturierter Daten durch LLMs sowie zur Automatisierung von ETL-Prozessen aufgearbeitet und gegeneinan-

der abgegrenzt. Auf dieser Basis wird die für diese Arbeit relevante Forschungslücke präzisiert. In Kapitel 4 wird die Konzeption der experimentellen Evaluierung beschrieben. Dies umfasst das Forschungsdesign, die Auswahl der untersuchten Modelle, die Definition der ETL-Aufgaben, die eingesetzten Prompting-Strategien sowie die Evaluationskriterien einschließlich der klassischen Baseline. Kapitel 5 dokumentiert anschließend die Erstellung des synthetischen Datensatzes, einschließlich Anforderungen, Datenmodell, eingebauter Qualitätsprobleme und der durchgeführten Validierung. Die technische Umsetzung wird in Kapitel 6 dargestellt. Es beschreibt die Systemarchitektur, die eingesetzten Technologien sowie die konkrete Implementierung der klassischen ETL-Pipeline und der LLM-basierten Komponenten. Kapitel 7 behandelt die Durchführung der Experimente und legt Versuchsablauf, erhobene Messdaten sowie die Bedingungen zur Sicherstellung der Reproduzierbarkeit offen. Kapitel 8 präsentiert und analysiert die Ergebnisse. Neben einer aufgabenspezifischen Auswertung erfolgen ein Vergleich der Modelle, der Prompting-Strategien sowie eine Gegenüberstellung von KI-basiertem und klassischem Ansatz. Die Ergebnisse werden anschließend diskutiert und in den Stand der Forschung eingeordnet. Aus den gewonnenen Erkenntnissen leitet Kapitel 9 Handlungsempfehlungen für die Praxis ab, insbesondere zur Eignung von LLMs in unterschiedlichen ETL-Szenarien sowie zur Gestaltung hybrider Architekturen. Kapitel 10 fasst die zentralen Ergebnisse zusammen, beantwortet die in Abschnitt 1.2 formulierten Forschungsfragen, reflektiert die Limitationen der Arbeit und gibt einen Ausblick auf weiterführende Forschungsfragen.

2. Grundlagen

2.1 ETL-Prozesse

2.1.1 Definition und Phasen

2.1.2 Typische Herausforderungen

2.1.3 Klassische Werkzeuge und Verfahren

2.2 Datenqualität und Datenbereinigung

2.2.1 Dimensionen der Datenqualität

2.2.2 Häufige Datenprobleme

2.3 Large Language Models

2.3.1 Funktionsweise und Architektur

2.3.2 Überblick aktueller Modelle

2.3.3 Stärken und Limitationen bei strukturierten Daten

2.4 Prompt Engineering

2.4.1 Grundlegende Prompting-Strategien

2.4.2 Einflussfaktoren auf die Ergebnisqualität

3. Stand der Forschung

3.1 KI-Einsatz in der Datenverarbeitung

3.2 LLMs für strukturierte Daten und Tabellen

Bibliography

- Chakraborty, S. (2025). Beyond ETL: How AI Agents Are Building Self-Healing Data Pipelines. *Journal of Computer Science and Technology Studies*, 7(3), 741–756. <https://doi.org/10.32996/jcsts.2025.7.3.81>
- Hassani, H., & Silva, E. S. (2023). The Role of ChatGPT in Data Science: How AI-Assisted Conversational Interfaces Are Revolutionizing the Field. *Big Data and Cognitive Computing*, 7(2), 62. <https://doi.org/10.3390/bdcc7020062>
- Khan, B., Saifullah, J., Khan, W., & Chughtai, M. (2024). An Overview of ETL Techniques, Tools, Processes and Evaluations in Data Warehousing. *Journal on Big Data*, 6, 1–20. <https://doi.org/10.32604/jbd.2023.046223>
- Khan, J. (2025). Leveraging Artificial Intelligence to Automate ETL Pipelines: Evolving Legacy Data Systems into Intelligent Workflows.
- Mishra, S. (2020). Automating the data integration and ETL pipelines through machine learning to handle massive datasets in the Enterprise. *International Journal of Emerging Research in Engineering and Technology*, 1(2), 69–78. <https://doi.org/10.63282/3050-922X.IJERET-V1I2P109>
- Nagabhyru, K. C. (2022, November 24). *Bridging Traditional ETL Pipelines with AI Enhanced Data Workflows: Foundations of Intelligent Automation in Data Engineering*. 5505199. <https://doi.org/10.2139/ssrn.5505199>
- Ravi, C. (2025). ETL (Extract, Transform & Load) Automation. *International Journal of Emerging Trends in Computer Science and Information Technology*, 6(1), 52–55. <https://doi.org/10.63282/3050-9246.IJETCSIT-V6I1P106>
- Walha, A., Ghazzi, F., & Gargouri, F. (2024). Data integration from traditional to big data: Main features and comparisons of ETL approaches. *The Journal of Supercomputing*, 80(19), 26687–26725. <https://doi.org/10.1007/s11227-024-06413-1>
- Zhao, W. X., Zhou, K., Li, J., Tang, T., Wang, X., Hou, Y., Min, Y., Zhang, B., Zhang, J., Dong, Z., Du, Y., Yang, C., Chen, Y., Chen, Z., Jiang, J., Ren, R., Li, Y., Tang, X., Liu, Z., . . . Wen, J.-R. (2026, March 18). *A Survey of Large Language Models*. arXiv: 2303.18223 [cs]. <https://doi.org/10.48550/arXiv.2303.18223>